

Desenvolvimento de uma CNN para classificar personagens de Big Bang Theory

Deivid Braian Smarzaro



Introdução

Labels:

leonard: 23 samples howard: 68 samples sheldon: 176 samples

raj: 70 samples total 337 samples

kaggle























Pré-processamento dos dados

```
img_size = 50
#Enumera os labels
class_dict = {}
#celebrity file names dict contém apenas caminhos das imagens de cada personagem
for i,celebrity_name in enumerate(celebrity_file_names_dict.keys()):
    print(celebrity_name,end=' ')
    class_dict[celebrity_name] = i
    print(len(celebrity_file_names_dict[celebrity_name]), 'samples')
#Coloca todos os dados e seus labels em duas listas paralelas
x,y = [],[]
for k in celebrity_file_names_dict:
    for i,v in enumerate(celebrity_file_names_dict[k]):
        x.append(v)
       y.append(k)
print('total',len(x))
#Uniformiza o tamanho das imagens e as deixa P&B
for i.endereco in enumerate(x):
    gray = ImageOps.grayscale(Image.open(endereco))
    x[i] = (np.asarray(gray.resize((img_size,img_size))))
#Troca str para o int correspondente
for i,c in enumerate(y):
    v[i] = class_dict[c]
```



Pré-processamento dos dados

```
#Separa o treinamento do restante
x_train, x_rem, y_train, y_rem = train_test_split(x,y, train_size=0.7,random_state = 42)
#Separa o restante em validação e teste
x_valid, x_test, y_valid, y_test = train_test_split(x_rem,y_rem, train_size=0.5,random_state = 42)
```



One-Hot encoding

```
num_classes = 4

y_train = keras.utils.to_categorical(y_train, num_classes)
y_test = keras.utils.to_categorical(y_test, num_classes)
y_valid = keras.utils.to_categorical(y_valid, num_classes)

array([0., 0., 0., 1.], dtype=float32)
```



Normalização

```
x_valid = np.array(x_valid)
x_train = np.array(x_train)
x_test = np.array(x_test)
if x_train.max() == 255:
    x_valid = x_valid/255
    x_train = x_train/255
    x_test = x_test/255
```

```
array([[[0.48235294, 0.48627451, 0.40392157], [0.12156863, 0.12156863, 0.0627451], [0.0745098, 0.07058824, 0.01176471], ...,
```



Reshaping

```
#Mantém a quantidade e faz reshape para ter também a quantidade de canais na ultima dimensão, sendo gray, há apenas 1

x_train = x_train.reshape(-1,img_size,img_size,1)

x_valid = x_valid.reshape(-1,img_size,img_size,1)

x_test = x_test.reshape(-1,img_size,img_size,1)

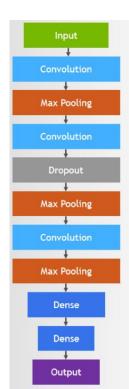
x_train.shape, x_test.shape, x_valid.shape

>>>((235, 28, 28, 1), (51, 28, 28, 1), (51, 28, 28, 1))
```

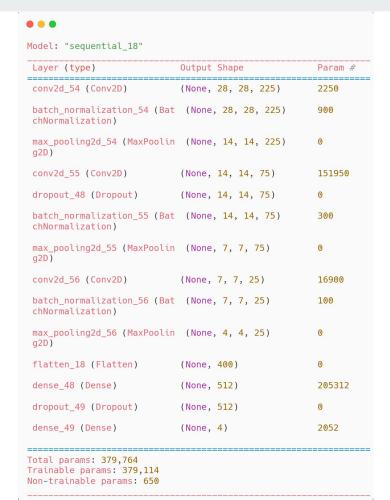


Desenvolvimento do Modelo

```
def create model(*args):
    name = str(args)
    model = Sequential()
    model.add(Conv2D(args[0], (3, 3), strides=1, padding="same", activation="relu",input_shape=(img_size, img_size,
3)))
    model.add(BatchNormalization())
    model.add(MaxPool2D((2, 2), strides=2, padding="same"))
    model.add(Conv2D(args[1], (3, 3), strides=1, padding="same", activation="relu"))
    model.add(Dropout(args[2]))
    model.add(BatchNormalization())
    model.add(MaxPool2D((2, 2), strides=2, padding="same"))
    model.add(Conv2D(args[3], (3, 3), strides=1, padding="same", activation="relu"))
    model.add(BatchNormalization())
    model.add(MaxPool2D((2, 2), strides=2, padding="same"))
    model.add(Flatten())
    model.add(Dense(units=args[4], activation="relu"))
    model.add(Dropout(args[5]))
    model.add(Dense(units=args[4], activation="relu"))
    model.add(Dropout(args[5]))
    model.add(Dense(units=num_classes, activation="softmax"))
    model.compile(loss="categorical crossentropy",optimizer = 'adam', metrics=["accuracy"])
    return model, name
```



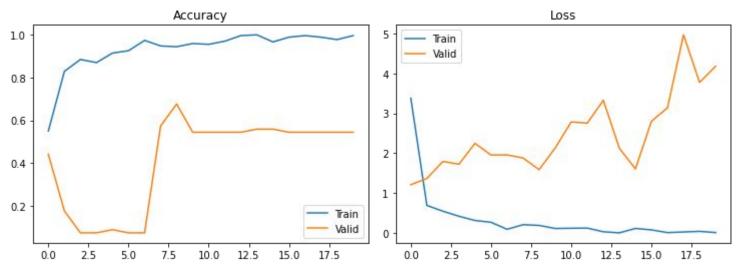
Summary do Modelo







1ª Tentativa com os mesmos parâmetros do curso (Imagem 80x80) - Parâmetros (75, 50, 0.2, 25, 512, 0.2)





Data augmentation

```
datagen = ImageDataGenerator(
    #samplewise_center=True, # set each sample mean to 0
    rotation_range=10, # randomly rotate images in the range (degrees, 0 to 180)
    zoom_range=0.1, # Randomly zoom image
   width shift range=0.1, # randomly shift images horizontally (fraction of total width)
    height_shift_range=0.1, # randomly shift images vertically (fraction of total height)
    horizontal flip=True, # randomly flip images horizontally
   vertical_flip=False, # Don't randomly flip images vertically
batch size = 32
img_iter = datagen.flow(x_train, y_train, batch_size=batch_size)
```



Data augmentation visualization





























































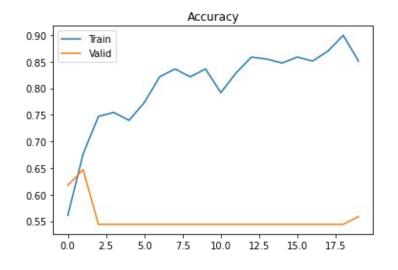


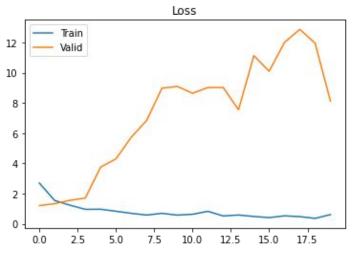






2ª Tentativa com os mesmos parâmetros do curso e usando o gerador(Imagem 80x80)



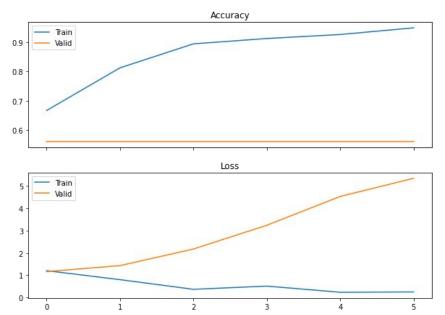




Early Stop

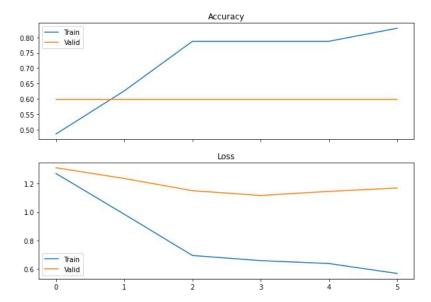


3° Tentativa (Imagem 100x100) - Parâmetros (225, 100, 0.2, 25, 512, 0.2); batch_size = 32





4^a Tentativa (Imagem 28x28) - Parâmetros (80, 20, 0.4, 5, 256, 0.2); batch_size = 16





Tentativa em RGB

























































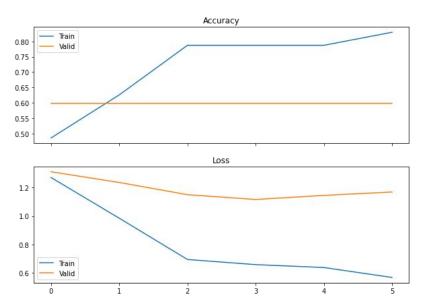








5^a Tentativa (Imagem 50x50 RGB) - Parâmetros (225, 75, 0.2, 25, 512, 0.2); batch_size = 32





Salvando o Modelo

```
model.save('Last Model')
!zip -r /content/Last_Model.zip /content/Last_Model
files.download('Last_Model.zip')
model = keras.models.load_model('Last_Model')
```



Aplicação da Validação

```
#Recupera o model salvo
model = keras.models.load_model('Last_Model')
correct = 0
for xv,yv in zip(x_valid,y_valid):
    #Realiza o predict para cada imagem no set "valid"
   pred=model.predict(xv.reshape(1,img size,img size,1))
   print(pred)
   #Plota a imagem
   plt.imshow(xv.reshape(img_size,img_size),cmap='gray')
    #Compara as respostas obtidas com o gabarito
   print('resposta:',list(class_dict.keys())[np.argmax(pred)],'. Correto:',list(class_dict.keys())
[np.argmax(yv)],'\n')
    if list(class_dict.keys())[np.argmax(pred)]==list(class_dict.keys())[np.argmax(yv)]:
        correct+=1
    #Exibe
   plt.show()
   print('\n')
#Compilado de % de acerto ao final
print(correct/len(x_valid)*100,'% de acerto')
```



Validação

(Imagem 28x28) - Parâmetros (225, 75, 0.2, 25, 512, 0.2); batch_size = 32

54.9 % de acerto

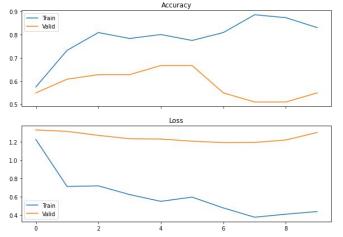


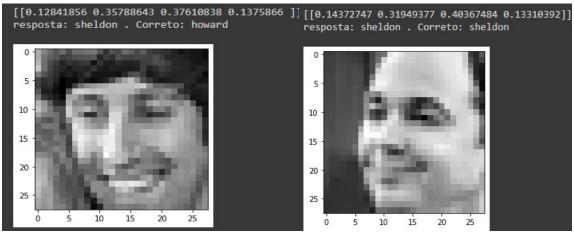


Resultados e Validação

6^a Tentativa (Imagem 28x28) - Parâmetros (75, 50, 0.2, 25, 512, 0.2); batch_size = 32

66.6% de acerto







Outras tentativas sem progresso em val_accuracy

Alterar taxas de dropout entre 0.1 e 0.5

Adicionar mais um conjunto de Conv2D, Maxpooling e BatchNormalization

Duplicar a quantidade de camadas Conv2D

Adicionar uma camada Dense

Diversas combinações de tamanhos das camadas Conv2D

Reduzir quantidade de imagens de sheldon para 60



Conclusões

- Desenvolvimento de conhecimento do funcionamento e layers de uma CNN
- Uso e boas práticas em Keras
- Metodologia para realizar pré-processamento dos dados
- Visualização geral dos dados
- Detecção de overfitting
- Métodos para evitar overfitting, como Data Augmentation e Early Stop
- Possíveis causas para o overfit: Base desbalanceada; layers insuficientes ou desconfigurados



Obrigado